

PCA (Principle Component Analysis)

2017010698
수학과 오서영

**지도 학습 (Supervised Learning) : 답지 달린 시험 족보를 주고
학습**

-> 답을 찾기 위해 활용, labeling O

**비지도 학습 (Unsupervised Learning) : 답을 맞히는 목적 X
-> labeling X**


1) Clustering : k - means , DB-SCAN

2) PCA

PCA



- 1) 이미지와 같은 고차원 데이터에서 패턴을 찾는 도구
- 2) 데이터를 인공 신경망에 입력하기 전의 전처리 과정에서 PCA가 사용되곤 한다.
- 3) PCA를 통해 데이터의 범위를 재조정하고 데이터의 평균을 0으로 맞춰줌으로써 PCA는 고차원 데이터 중 중요한 차원을 골라준다.
- 4) 신경망 학습의 수렴 속도와 성능 향상

PCA





차원 축소
→ 정사영

겹치는 점
→ 정보유실



PCA



정보 유실이
가장 적게 일어나는 축
→ 데이터의 분산이
최대가 되는 축

과정

- 1) 학습 데이터 셋에서 분산이 최대인 축을 찾는다.
 - 2) 첫 번째 축과 직교하면서 분산이 최대인 두 번째 축을 찾는다.
 - 3) 첫 번째 축과 두 번째 축에 직교하고 분산을 최대한 보존하는 세 번째 축을 찾는다.
 - 4) 1~3과 같은 방법으로 데이터셋의 차원(특성 수)만큼의 축을 찾는다.
- > i -번째 주성분 (PC) : i -번째 축을 정의하는 단위 벡터

계산

$$\begin{aligned} \text{Var} [\mathbf{X}\vec{e}] &= \frac{1}{m-1} \sum_{i=1}^m [X\vec{e} - E(X\vec{e})]^2 \\ &= \frac{1}{m-1} \sum_{i=1}^m [X\vec{e} - E(X)\vec{e}]^2, \quad (E(X) = 0) \\ &= \frac{1}{m-1} \sum_{i=1}^m (X\vec{e})^2 \\ &= \frac{1}{m-1} (\mathbf{X}\vec{e})^T (\mathbf{X}\vec{e}) \\ &= \frac{1}{m-1} \vec{e}^T \mathbf{X}^T \mathbf{X} \vec{e} \\ &= \vec{e}^T \left(\frac{\mathbf{X}^T \mathbf{X}}{m-1} \right) \vec{e}, \quad \left(\frac{\mathbf{X}^T \mathbf{X}}{m-1} = \mathbf{C} \right) \\ &= \vec{e}^T \mathbf{C} \vec{e} \end{aligned}$$

X : 평균을 0으로
조정된 데이터

e : 투영할 축의
단위벡터

계산

$$\text{maximize } \vec{e}^T \mathbf{C} \vec{e}$$

$$\text{s.t. } \|\vec{e}\|^2 = 1$$

$$L(\vec{e}, \lambda) = \vec{e}^T \mathbf{C} \vec{e} - \lambda (\vec{e}^T \vec{e} - 1)$$

$$\begin{aligned} \frac{\partial L}{\partial \vec{e}} &= (\mathbf{C} + \mathbf{C}^T) \vec{e} - 2\lambda \vec{e} \\ &= 2\mathbf{C} \vec{e} - 2\lambda \vec{e} = 0 \end{aligned}$$

$$\therefore \mathbf{C} \vec{e} = \lambda \vec{e}$$

$$\therefore \mathbf{C} = \vec{e} \lambda \vec{e}^T$$

$$\mathbf{C} \vec{e} = \lambda \vec{e}$$

e : 공분산 C 의
단위벡터

Lambda :
(C 의 고유값)
= (eigenvector
로 투영했을 때의
분산)

예시

